

Correlación de cantidades físicas

Basado en el capítulo '10: Correlation of physical quantities' del libro The Uncertainty in Physical Measurements de Paolo Fornasini

27 de febrero de 2025

Brenda **Alderete**, Gastón **Barcala Berengard**, Sol **Berns**

¿Por qué nos interesa estudiar la correlación?

- Correlación: relación funcional entre dos (o más) magnitudes.
- Permiten inducir, por ejemplo, leyes físicas.
Condición necesaria pero no suficiente !!!
- La incertidumbre juega un rol importante en la fiabilidad de las relaciones, ya que afecta a **todas** las mediciones.

Objetivo

Introducir técnicas útiles para reconocer la existencia de correlación entre dos cantidades y expresarlo de forma funcional, considerando también la incerteza de las mediciones.

Relaciones entre cantidades físicas

Consideremos cantidades físicas X, Y .


Se mide X N veces, obteniendo valores $x_i, \delta x_i$.

Para X cada se miden $y_i, \delta y_i$.


Obtenemos N pares de valores $x_i \pm \delta x_i, \quad y_i \pm \delta y_i, \quad (i = 1, \dots, N)$

Podemos observar los datos en una tabla o en un gráfico!

Posibles casos




¿Relación lineal?



$$Y = A + BX$$

¿Quiénes son A , B ?



¿Relación funcional?

Varianza y covarianza muestral

N pares (x_j, y_j) , $\xi = x, y$


media \downarrow $m_{\xi}^* = \frac{1}{N} \sum_j \xi_j$, \uparrow $D_{\xi}^* = \frac{1}{N} \sum_j (\xi_j - m_{\xi}^*)^2$, \downarrow desviación estándar $\sigma_{\xi}^* = \sqrt{D_{\xi}^*}$

varianza (dispersión)

La covarianza de la muestra queda $\sigma_{xy}^* = \frac{1}{N} \sum_j (x_j - m_x^*)(y_j - m_y^*)$

Reminder:

* = de la muestra



Advertencia: Diferencia con el *capítulo 8* respecto a significado de **varianza** y **covarianza**.

Antes: Fluctuaciones aleatorias de dos valores x_j e y_j con sus respectivas medias, conectadas a la incerteza.

Coeficiente de correlación lineal

r para los amigos, o también conocido como coeficiente de Pearson

Para determinar qué tan linealmente correlacionadas están dos magnitudes, usamos r :

$$r \equiv \frac{\sigma_{xy}^*}{\sigma_x^* \sigma_y^*} = \frac{\sum_j (x_j - m_x^*)(y_j - m_y^*)}{\sqrt{\sum_j (x_j - m_x^*)^2} \sqrt{\sum_j (y_j - m_y^*)^2}}$$

Y por la desigualdad de Cauchy-Schwartz

$$|\sigma_{xy}^*| \leq \sigma_x^* \sigma_y^* \Rightarrow |r| \leq 1$$

Ejemplo: correlación lineal perfecta

¿Cómo interpretamos el valor de r ?

Cantidades $X, Y \rightsquigarrow Y = A + BX$

Par de valores (x_i, y_i) y medias m_x^*, m_y^*

$$\begin{cases} y_i = A + Bx_i \\ m_y^* = A + Bm_x^* \end{cases} \xrightarrow{(-)} y_i - m_y^* = B(x_i - m_x^*)$$

por eso $|r|=1$ es buena señal cuando hacemos un ajuste !!!


$$r = \frac{\sum_j (x_j - m_x^*)(y_j - m_y^*)}{\sqrt{\sum_j (x_j - m_x^*)^2} \sqrt{\sum_j (y_j - m_y^*)^2}} = \frac{B}{|B|} = \begin{cases} +1, & B > 0 \\ -1, & B < 0 \end{cases}$$



Entusiasmo

¿ $|r|=1$ qué implica?

Y que no ...




Bestfit Line
Correlation = $R = 0.245$

The actual best fit
Inspired by Causality

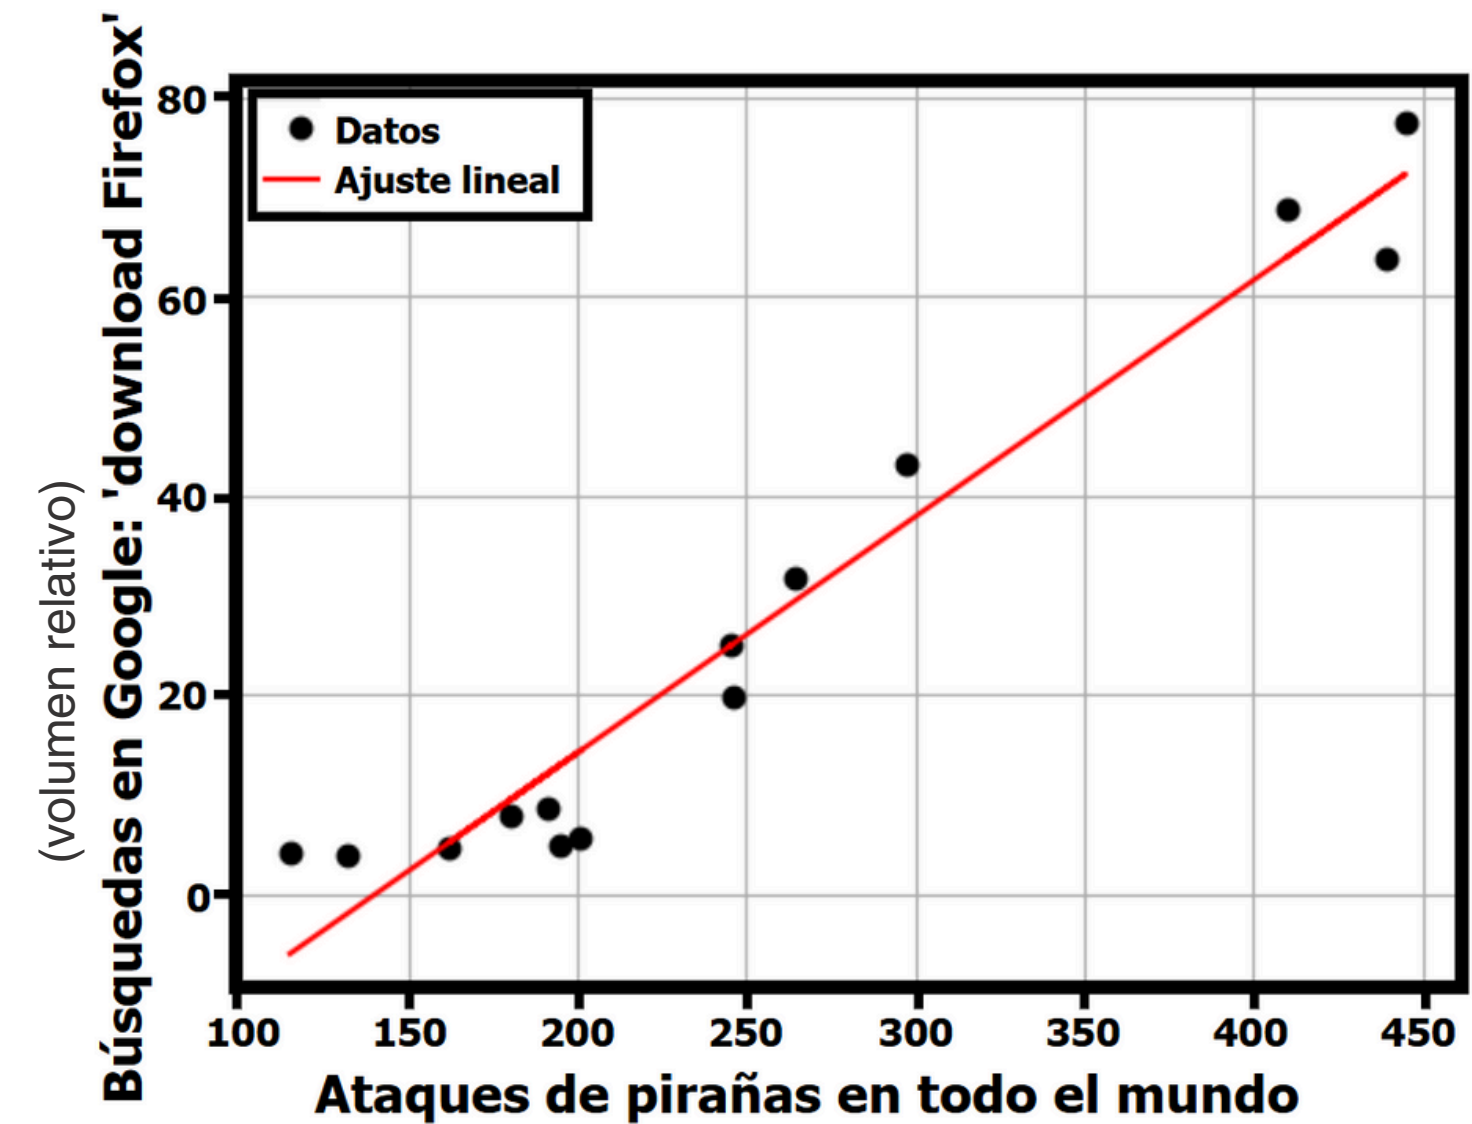
¿ $|r|=1$ qué implica?

Y que no ...



Bestfit Line
Correlation = $R = 0.245$

The actual best fit
Inspired by Causality

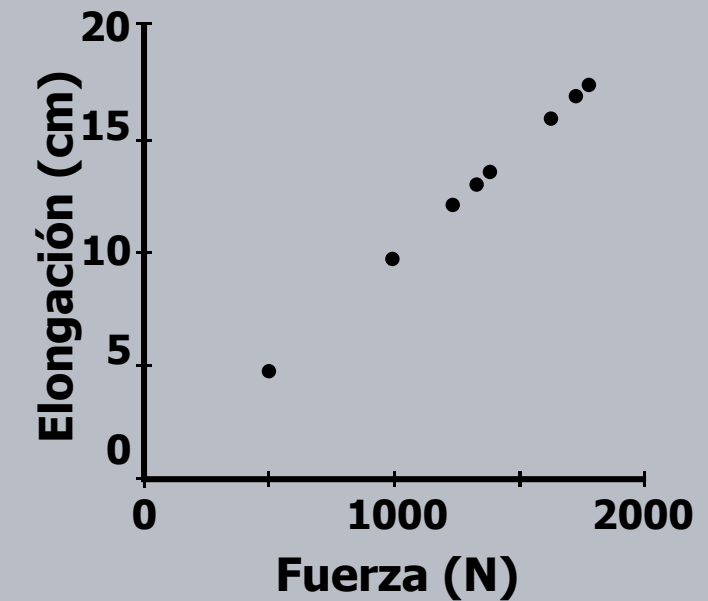


Cada punto representa un año entre 2009 y 2022

$$r = 0.97$$

Relaciones lineales entre dos cantidades

$$Y = A + BX$$



$$Y = A + BX$$

¿Quiénes son A, B ?

Tenemos dos objetivos:

- Encontrar A y B \rightarrow Regresión lineal
- Evaluar si, efectivamente, la relación es lineal \rightarrow Test de Hipótesis (Capítulo 11)

Regresión lineal

Basado en cuadrados mínimos

Se quiere minimizar la discrepancia total entre datos y recta.

Hipótesis

δx_i es despreciable

chi cuadrado

distancia entre los datos y la recta

$w_i = 1/(\delta y_i)^2$ peso de cada incerteza

$$\chi^2 = \sum_{i=1}^N \frac{(y_i - A - Bx_i)^2}{(\delta y_i)^2} = \sum_{i=1}^N w_i (y_i - A - Bx_i)^2$$

¡Sólo es función de A y B !


$$\chi^2 = \chi^2(A, B) \Rightarrow A, B / \begin{cases} \partial_A \chi^2 = 0 \\ \partial_B \chi^2 = 0 \end{cases}$$

$$\begin{cases} \partial_A \chi^2 = 0 \\ \partial_B \chi^2 = 0 \end{cases} \Rightarrow \begin{cases} (\sum_i w_i)A + (\sum_i w_i x_i)B = \sum_i w_i y_i \\ (\sum_i w_i x_i)A + (\sum_i w_i x_i^2)B = \sum_i w_i x_i y_i \end{cases}$$

Sistema 2×2
en A, B

Solución \rightarrow
$$\begin{cases} A = \frac{(\sum_i w_i x_i^2)(\sum_i w_i y_i) - (\sum_i w_i x_i)(\sum_i w_i x_i y_i)}{\Delta_w} \\ B = \frac{(\sum_i w_i)(\sum_i w_i x_i y_i) - (\sum_i w_i y_i)(\sum_i w_i x_i)}{\Delta_w} \end{cases}$$

con $\Delta_w = (\sum_i w_i)(\sum_i w_i x_i^2) - (\sum_i w_i x_i)^2$



Por suerte las
cuentas las hace
la compu :)

Considerando los errores en X


1. Calculamos A', B' considerando sólo error $(\delta y_i)_{\text{experimental}}$
2. Transformamos los errores en X a errores en $Y \longrightarrow (\delta y_i)_{\text{transformada}} = |B'|(\delta x_i)_{\text{exp}}$
3. Sumamos las contribuciones cuadráticamente $\longrightarrow (\delta y_i)_{\text{tot}}^2 = (\delta y_i)_{\text{exp}}^2 + (\delta y_i)_{\text{tra}}^2$
4. Calculamos A, B de la misma forma que antes, con $w_i = 1/(\delta y_i)_{\text{tot}}^2$

Pero esto podría no funcionar si los δx_i son grandes



Considerando los errores en X : Algoritmo ODR (orthogonal distance regression)

The cool way



```
import scipy.odr as odr

# Defino función lineal para el ajuste
def lineal(B,x):
    return B[0]*x + B[1] # B[0] = pendiente, B[1] = ordenada

# Configuro modelo en ODR
data = odr.RealData (x, y, sx = error_x, sy = error_y)
modelo = odr.Model(lineal)
odr_instancia = odr.ODR(data, modelo, beta0=[1,1])

# Ejecuto ajuste
resultado = odr_instancia.run()

# Obtengo parámetros ajustados y errores
slope, ordenada = resultado.beta
err_slope, err_ordenada = resultado.sd_beta
```

Errores en A y B

Recordemos

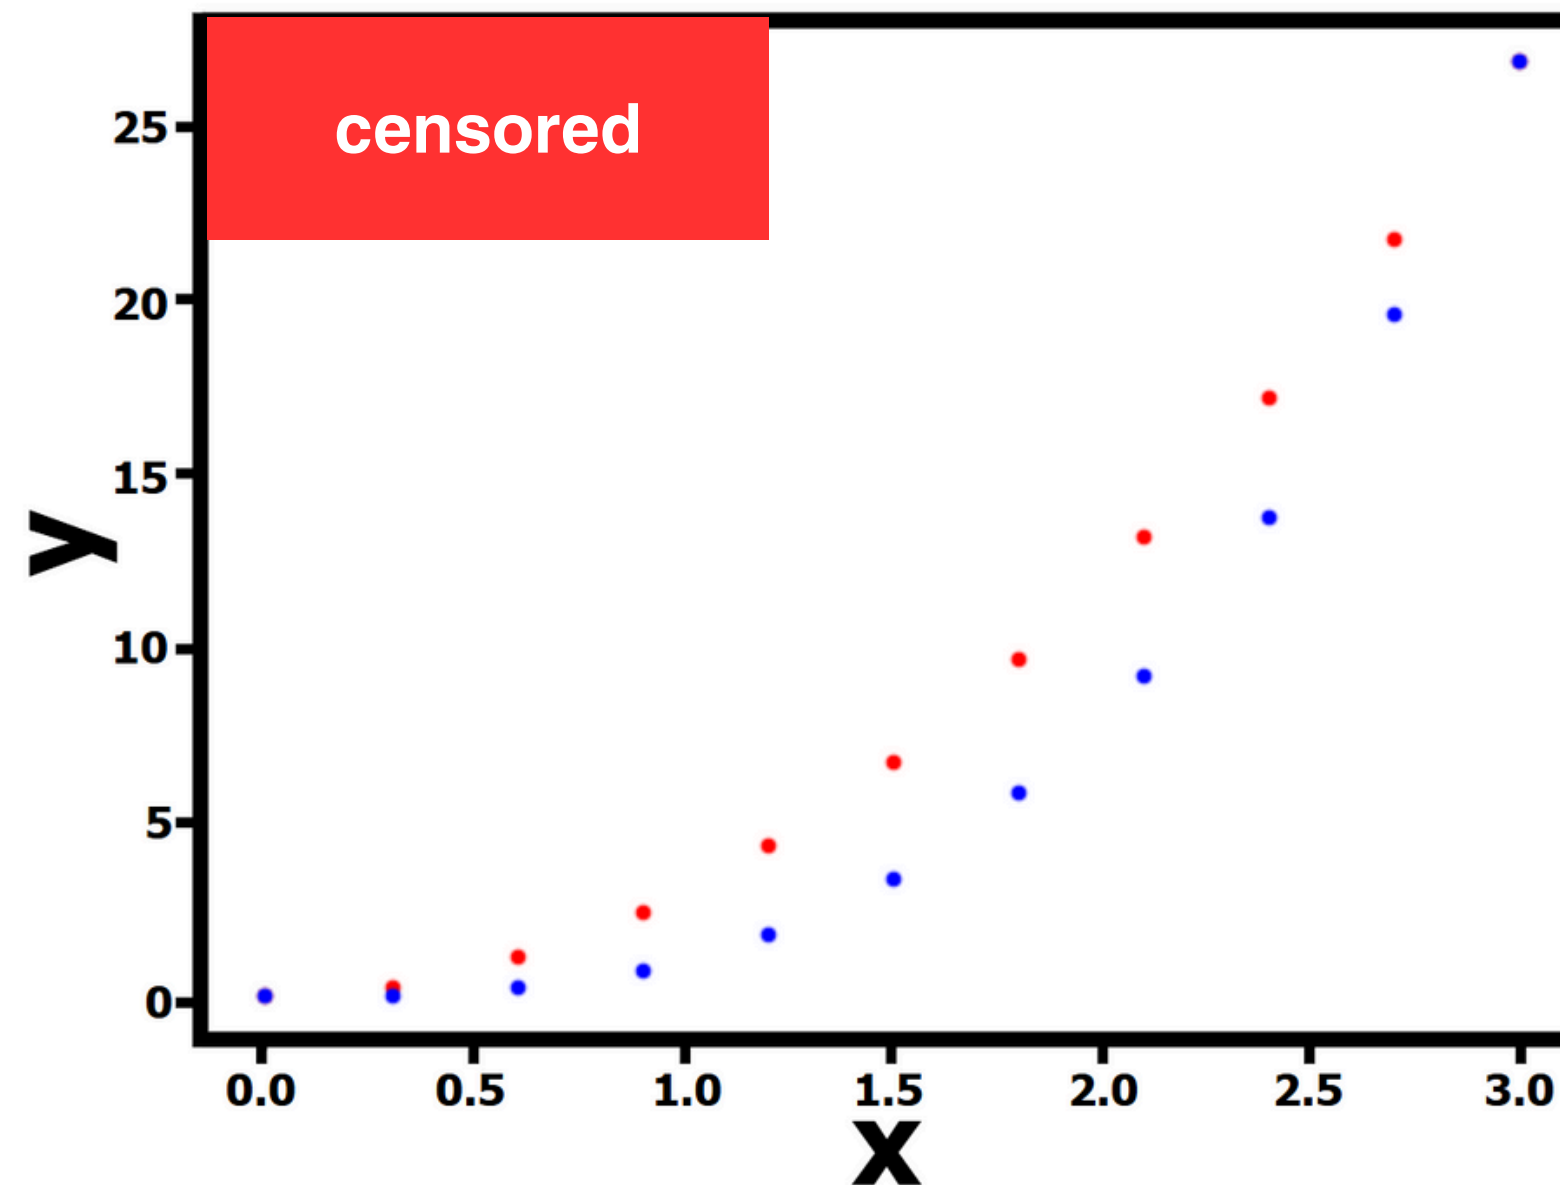
$$\begin{cases} A = \frac{(\sum_i w_i x_i^2)(\sum_i w_i y_i) - (\sum_i w_i x_i)(\sum_i w_i x_i y_i)}{\Delta_w} \\ B = \frac{(\sum_i w_i)(\sum_i w_i x_i y_i) - (\sum_i w_i y_i)(\sum_i w_i x_i)}{\Delta_w} \end{cases}, \quad \Delta_w \neq \Delta_w(y_i)$$

A, B son lineales en y_i !

$$\begin{cases} A = \sum_i \alpha_i y_i \\ B = \sum_i \beta_i y_i \end{cases} \xrightarrow[\text{con } (\delta y_i)^2 = 1/w_i]{\text{propagando}} \begin{cases} (\delta A)^2 = \sum_i \alpha_i^2 (\delta y_i)^2 = \frac{\sum_i w_i x_i^2}{\Delta_w} \\ (\delta B)^2 = \sum_i \beta_i^2 (\delta y_i)^2 = \frac{\sum_i w_i}{\Delta_w} \end{cases}$$


Linealización de relaciones no lineales

¿Cuál es la parábola y cuál la cúbica?



Linealización de relaciones no lineales

¿Cuál es la parábola y cuál la cúbica?



Linealización de relaciones no lineales


$$Y = \phi(X) \longrightarrow Y = A + BX$$

$$Y = \phi^{-1}[\phi(X)]$$

Con el mismo ejemplo

$$\phi_2^{-1} = \sqrt{y_2}$$

$$\phi_3^{-1} = \sqrt[3]{y_3}$$



Pero la vida, a veces, es no lineal...
(y por eso es difícil)

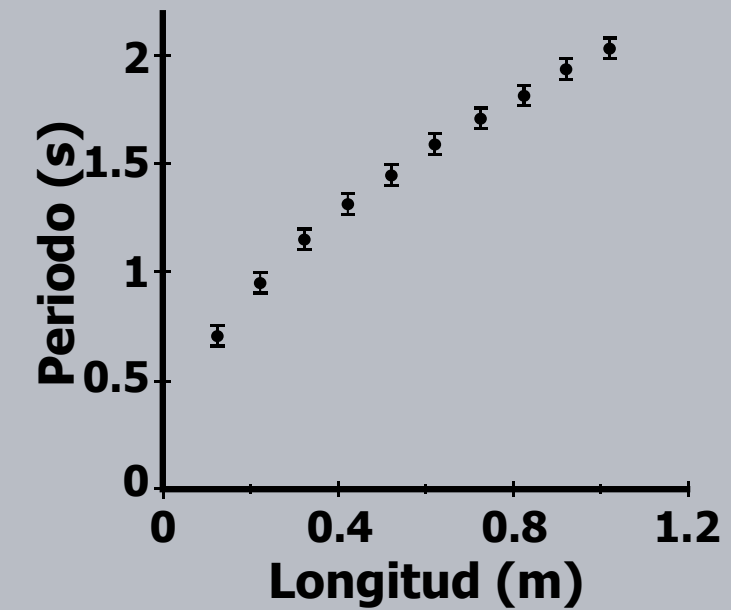
$$Y = A \exp(-\gamma X) \sin(\omega_0 X + \vartheta)$$

Relaciones entre variables

Fundamento la regresión lineal con **máxima verosimilitud**

Tengo N pares de valores medidos, de dos magnitudes físicas X, Y :

$$(x_i \pm \delta x_i, y_i \pm \delta y_i)$$



¿Relación funcional?

SE BUSCA!! $Y = \phi(X, \{\lambda_k\})$ con $\lambda_1, \lambda_2, \dots, \lambda_k$ parámetros de la función

Ejemplo: $Y = A + BX \longrightarrow Y = \lambda_1 + \lambda_2 X$


→ Procedimiento:

1. Definir la forma de la función.

2. Determinar parámetros.

Máxima verosimilitud y cuadrados mínimos

Se deriva del principio de verosimilitud bajo dos hipótesis

- $\delta x_i = 0, \delta y_i \neq 0$
- $\delta y_i = \sigma_i$
 desviación estándar $\tilde{\sigma}_i[m_i^*]$

Dado λ_i , la probabilidad de observar y_i para un dado x_i sigue la distribución:

$$f(y_i) = \frac{1}{\sigma_i \sqrt{2\pi}} \exp \left\{ - \frac{[y_i - \phi(x_i, \{\lambda_i\})]^2}{2\sigma_i^2} \right\}$$

Para N observaciones independientes, la densidad conjunta

$$g(y_1, \dots, y_N; \{\lambda_k\}) = \frac{1}{(\prod_i \sigma_i)(2\pi)^{N/2}} \exp \left\{ - \frac{1}{2} \sum_{i=1}^N \frac{[y_i - \phi(x_i, \{\lambda_k\})]^2}{\sigma_i^2} \right\}$$

χ^2

Minimización para funciones lineales

$$\phi(X, \{\lambda_k\}) = \sum_{k=1}^p \lambda_k h_k(X)$$

Cantidad de parámetros λ_k funciones de X

$$\chi^2 = \sum_{i=1}^N \frac{[y_i - \phi(x_i, \{\lambda_k\})]^2}{\sigma_i^2}$$

Si quiero valores óptimos de $\lambda_k \rightsquigarrow \frac{\partial \chi^2}{\partial \lambda_k} = \sum_{i=1}^N \frac{2}{\sigma_i^2} h_k(x_i) \left[y_i - \sum_{j=1}^p \lambda_j h_j(x_i) \right] = 0$

Linealidad de:

- λ_k : Permite analíticamente minimizar el χ^2
- X : Sólo se cumple en regresión lineal simple.

Minimización para funciones no lineales

$$Y = ae^{bX} \curvearrowright \ln Y = \ln a + bX \equiv Y' \longrightarrow \text{cantidad linealizada} \text{ 😊}$$

$$Y = Ae^{-\gamma X} \sin(\omega_0 X + \vartheta) \text{ 😞}$$

Reminder:
La linealización es en λ

Tomo rangos de valores: $A \in (0, 10)$, $\omega_0 \in (1, 5)$,
 $\gamma \in (0, 2)$, $\vartheta \in (0, 2\pi)$.

Elijo un número n de valores posibles para cada parámetro.

Para cada conjunto de datos calculo χ^2 .

Obstáculo: Cantidad de combinaciones

Considerando incertezas en X

Recordar:

$$\delta x_i = 0, \delta y_i \neq 0$$

$$\delta y_i = \sigma_i$$

Pasos a seguir:

1. Primer ajuste sin considerar incertezas $\longrightarrow \lambda'_k$

2. Propagacion de incertidumbre de X a Y $\longrightarrow (\delta y_i)_{\text{tra}} = \left| \frac{d\phi'(X, \{\lambda'_k\})}{dX} \right|_{x_i} (\delta x_i)_{\text{exp}}$

3. Calculo de incertidumbre total en Y $\longrightarrow (\delta y_i)_{\text{tot}}^2 = (\delta y_i)_{\text{exp}}^2 + (\delta y_i)_{\text{tra}}^2$

4. Ajuste con incertidumbre corregida $\longrightarrow \sigma_i = (\delta y_i)_{\text{tot}}$

Evaluación a posteriori de la incertidumbre en Y

1. Minimizamos la suma de residuos al cuadrado $\psi^2 \equiv \sum_{i=1}^N [y_i - \phi(X, \{\lambda_k\})]^2$.

2. Estimamos la incertidumbre media $\sigma^2 = \frac{1}{N} \sum_i [y_i - \phi(X, \{\lambda_k\})]^2$
por máxima verosimilitud .

3. Corrección por grados de libertad $\sigma^2 = \frac{1}{N - p} \sum_i [y_i - \phi(X, \{\lambda_k\})]^2$.

Gracias :)

¿Consultas?

**Escanea el QR para acceder al capítulo, nuestro contacto,
y a las diapos!**

